한국컴퓨터정보학회 하계학술대회 논문집 제29권 제2호 (2021. 7)

# 벡터 기반 데이터 증강과 인공신경망 기반 특징 전달을 이용한 효율적인 균열 데이터 수집 기법

윤주영[O], 김동희[*], 김종현[*]
[O]강남대학교 소프트웨어응용학부,
[*]강남대학교 소프트웨어응용학부
e-mail: jonghyunkim@kangnam.ac.kr

# Efficient Collecting Scheme the Crack Data via Vector based Data Augmentation and Style Transfer with Artificial Neural Networks

Ju-Young Yun[O], Donghui Kim[*], Jong-Hyun Kim[*]
[O]School of Software Application, Kangnam University,
[*]School of Software Application, Kangnam University

● 요 약 ●

본 논문에서는 벡터 기반 데이터 증강 기법(Data augmentation)을 제안하여 학습 데이터를 구축한 뒤, 이를 합성곱 신경망(Convolutional Neural Networks, CNN)으로 실제 균열과 가까운 패턴을 표현할 수 있는 프레임워크를 제안한다. 건축물의 균열은 인명 피해를 가져오는 건물 붕괴와 낙하 사고를 비롯한 큰 사고의 원인이다. 이를 인공지능으로 해결하기 위해서는 대량의 데이터 확보가 필수적이다. 하지만, 실제 균열 이미지는 복잡한 패턴을 가지고 있을 뿐만 아니라, 위험한 상황에 노출되기 때문에 대량의 데이터를 확보하기 어렵다. 이러한 데이터베이스 구축의 문제점은 인위적으로 특정 부분에 변형을 주어 데이터양을 늘리는 탄성왜곡(Elastic distortion) 기법으로 해결할 수 있지만, 본 논문에서는 이보다 향상된 균열 패턴 결과를 CNN을 활용하여 보여준다. 탄성왜곡 기법보다 CNN을 이용했을 때, 실제 균열 패턴과 유사하게 추출된 결과를 얻을 수 있었고, 일반적으로 사용되는 픽셀 기반 데이터가 아닌 벡터 기반으로 데이터 증강을 설계함으로써 균열의 변화량 측면에서 우수함을 보였다. 본 논문에서는 적은 개수의 균열 데이터를 입력으로 사용했음에도 불구하고 균열의 방향 및 패턴을 다양하게 생성하여 쉽게 균열 데이터베이스를 구축할 수 있었다. 이는 장기적으로 구조물의 안정성 평가에 이바지하여 안전사고에 대한 불안감에서 벗어나 더욱 안전하고 쾌적한 주거 환경을 조성할 것으로 기대된다.

**키워드:** 균열(Crack), 합성곱 신경망(Convolutional neural network), 데이터 증강(Data augmentation), 탄성왜곡(Elastic distortion), 데이터 수집 (Data collection), 뼈대 추출(Skeleton extraction)

## I. Introduction

인공신경망의 성능을 높이기 위해서는 가능한 많은 학습 데이터 셋이 필요하다. 특히 실제 균열 이미지는 상당히 복잡한 패턴을 지니고 있고, 균열이 발생한 건물을 직접 가야 하므로 때문에 위험한 상황에 노출되어, 일반적으로 대량의 데이터를 확보하기 어렵다. 본 논문에서는 데이터 셋 확장을 위한 데이터 증강기법 중 하나인 탄성왜곡기법을 연구하였으며[1,2], 이 과정에서 기존 데이터 증강 알고리즘에서의 한계점인 방향성 보존 및 변화에 대한 부분을 벡터 기반으로 접근하여 개선하였다. 탄성왜곡의 미시적인 디테일과 거시적 디테일을 통합하여 전체적인 데이터 변형과 품질을 한층 개선했으며, 이를 구현하기 위한 본 논문의 기여도는 다음과 같다 :

- 미시적과 거시적 디테일 관점에서 대량의 학습 데이터를 확보할 수 있는 벡터 기반의 탄성왜곡 기법 개발
- CNN을 통해 실제 균열의 패턴과 유사하게 이미지를 생성할 수 있는 균열 특징 전달 네트워크 개발

## II. The Proposed Scheme

본 논문에서 제안하는 벡터 기반 데이터 증강기법은 균열 이미지로부터 뼈대를 추출하고, 이로부터 특징점인 코너(Corner)를 찾아 연결한 선분을 활용한다.

### 1. 균열 데이터로부터의 뼈대 추출

실제 데이터의 95% 이상이 비 균열(Non-crack)이라고 했을 때 균열이 존재하는 영역은 매우 작은 부분에 불과하다. 그러므로 균열 라인에 데이터 변형을 가할 경우, 균열이 불규칙적으로 끊어지는 문제가 발생한다 (Fig. 1 참조).

(a) (b)

Fig. 1. Extracted skeleton data from crack image.

균열 라인의 연결성 유지를 위해 균열 이미지로부터 골격을 추출한다. 골격화는 라인을 픽셀기반에서 벡터 기반으로 변환하여 대상 물체의 두께를 얇은 벡터 선분으로 나타내는 방법이다. 이 과정을 거쳐 균열 이미지에서 뼈대를 추출하고, 선분 너비를 조절하여 네트워크 학습 데이터로 활용한다.

### 2. 코너 탐지

균열 데이터에서 기울기가 심하게 변하는 두 에지의 교차점인 모서리(Corner, 코너)를 검출한다. 이 기법은 에지 간 변화율을 계산하여 양방향 기울기의 변화가 심한 곳을 코너로 간주한다. 본 논문에서는 해리스 코너 검출 기법을 개선한 Shi-Tomashi 코너 감지 기법을 이용하였다[3,4]. 한 픽셀을 중심에 두고 윈도우 내에서 $X$축으로 $u$만큼 $Y$축으로 $v$만큼 이동하며 윈도우 내 픽셀 값들의 차이에 대한 제곱 합을 계산한다. 수식 1에서 $W(x,y)$는 $(x,y)$ 위치에서 윈도우의 가중치, $I(x+u,y+v)$는 이동된 위치에서의 값, $I(x,y)$는 이동 전 위치에서의 값을 의미한다.

$$E(u,v)=\sum_{x,y} W(x,y)\,[I(x+u,y+v)-I(x,y)]^2 \quad (1)$$

수식 1에 테일러 확장(Taylor Expansion)을 적용하면 수식 2를 얻을 수 있다.

$$E(u,v)\cong \sum_{x,y} [I(x,y)+uI_x+vI_y-I(x,y)]^2 \quad (2)$$

수식 3은 수식 2를 행렬식으로 바꿔 정리한 최종 방정식이다. 이때, 행렬의 고유 값이 최솟값보다 높으면 코너로 간주하였다.

$$E(u,v)\cong \quad [u,v]\left(\sum_{x,y} W(x,y)\begin{bmatrix} I^2x & I_xI_y \\ I_xI_y & I^2y \end{bmatrix}\right)\begin{bmatrix} u \\ v \end{bmatrix} \quad (3)$$

Fig. 2는 그레이스케일 이미지에서 원하는 코너 개수, 기울기 변화량, 코너 간 최소 거리를 지정하여 추출된 $N$개의 코너 집합이다.

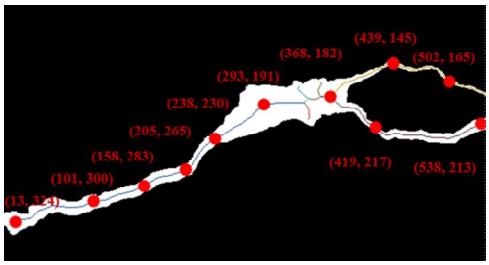


Fig. 2. Skeleton extraction and corner detection from crack image.

Fig. 3은 검출된 코너들을 선분으로 연결한 결과이며, 향후 이것을 벡터 증강 알고리즘에 활용한다.

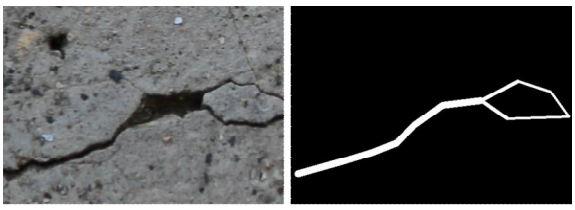

(a) (b)

Fig. 3. Crack vector with skeleton and corner set.

### 3. 벡터 기반 탄성 왜곡

이번 장에서는 미시적-거시적 관점에서 구현된 벡터 기반의 탄성왜곡 기법에 대해 설명한다. 미시적 관점에서는 표준편차 $\sigma$와 변형강도 $\alpha$의 가중치를 조절하여 균열에 심층적인 변형을 가하였다. Fig. 4는 앞서 추출한 코너를 연결한 선분 중 하나의 선분을 분할하여 확대한 결과이며, 그림에서도 보듯이 가중치에 따른 변형 정도를 쉽게 확인할 수 있다.

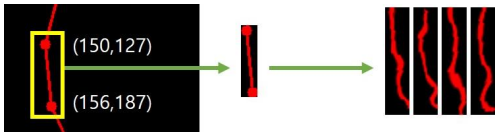


Fig. 4. Vector based elastic distortion in crack direction

거시적 관점의 탄성왜곡에서는 회전 각도와 아핀 변형(Affine transformation)의 가중치를 조절하여 균열의 표면 형태를 변형하였다.

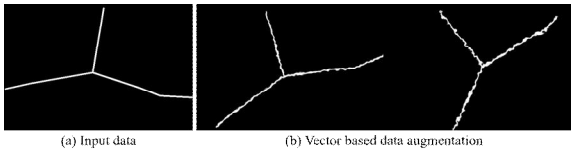


Fig. 5. Crack data augmentation with our method.

Fig. 5에서는 벡터 기반 선분을 활용하여 미시적-거시적 관점의 탄성왜곡 기법을 적용한 결과를 보여준다. 직선 형태의 균열에 비해 좀 더 다양한 방향성을 표현했으며, 전통적인 픽셀기반 데이터 증강에서는 이러한 방향성을 제어할 수 없다. 난수에 의해 이 문제를 일시적으로 피해갈 수는 있지만, 난수에 의한 변형은 원본 균열의 방향성을 잃어버릴 수 있어서 균열의 특징을 온전하게 표현하기에는 충분하지 않다.

## 4. 신경망을 통한 균열 특징 전달

이번 장에서는 인공신경망을 통해 균열 데이터의 디테일을 향상시키는 방법을 소개한다. CNN 학습을 위해 골격화 균열 이미지 500장, 벡터 기반 선분 이미지 400장을 확보하였으며, 이후 벡터 기반 데이터 증강기법을 통해 학습 데이터를 추가적로 수집하였다.

우리는 앞에서 얻은 균열 이미지들을 바탕으로 합성 곱 신경망 학습을 진행하여 실제 균열과 유사한 패턴을 얻을 수 있는 특징 전달(Feature transfer)에 대해 설명한다. 골격화 기법을 거친 균열 이미지를 바탕으로 네트워크 학습을 하였을 때 특징 점에 대한 해상도가 복잡하여 실제 학습 자체가 이뤄지지 않았지만, 균열의 코너를 추출한 뒤 선분으로 연결한 벡터 기반 데이터를 활용하여 이 문제를 해결하였다.

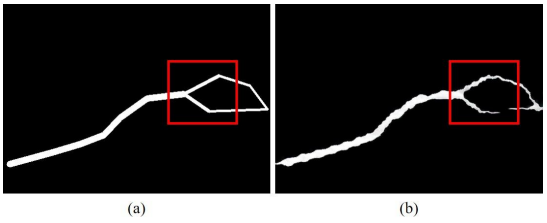


Fig. 6. Enhanced details of crack with CNN.

Fig. 6은 CNN 학습을 거쳐 생성된 실제 균열과 유사한 패턴의 이미지이다. CNN의 결과는 기존 탄성왜곡기법과 비교하여 볼 때, 탄성왜곡의 가중치가 큰 경우 발생하였던 노이즈로 인해 원본 균열의 특징을 온전하게 표현하지 못하였던 문제점을 해결했다. 최종적으로 Fig. 7과 같이 벡터 기반의 학습 이미지를 활용하여 26개의 레이어, 3배의 업샘플링, 잔차 이미지(Residual image)를 바탕으로 네트워크 학습을 하였을 때 최적의 결과를 얻었다.

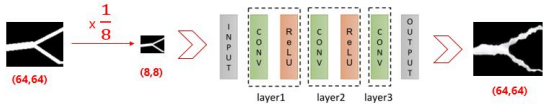


Fig. 7. Our neural network architecture.

업샘플링 배수가 커질수록 결과가 향상되었고, 잔차 이미지를 사용하며 3채널 학습의 색상 문제를 해결하였다. 마지막으로 확실한 균열 패턴의 디테일이 추출된 이미지를 얻기 위해 벡터 증강 과정을 거친 탄성왜곡 이미지를 입력 데이터로 CNN 학습을 진행하여 결과를 확인했다. Fig. 8에서 a는 입력 이미지, b는 가중치 변화에 따른 탄성왜곡을 거친 이미지에 대한 CNN의 학습 결과이다.

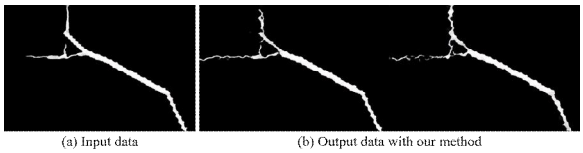


Fig. 8. variety crack dataset with our method.

## III. Conclusions

본 연구에서는 균열 감지 시스템의 성능 향상을 위해 새로운 벡터 기반 학습 데이터를 활용한 CNN 기법을 제안했다. 복잡한 패턴을 지닌 균열의 이미지를 확보하기 위한 탄성왜곡 기반의 데이터 증강 기법을 이용해 네트워크를 학습시키고, CNN을 활용해 실제 균열의 특징과 유사하게 변형된 대량의 균열 이미지를 얻었다. 향후, 우리는 보다 다양한 이미지에서 균열을 추출하고, 서로 다른 수준의 특징 맵들을 합쳐 좀 더 정확한 특징을 추출할 수 있는 기법에 관해 연구할 계획이다.

## REFERENCES

[1] Shorten, Connor, and Taghi M. Khoshgoftaar. A survey on image data augmentation for deep learning. Journal of Big Data, vol. 6, pp. 1-48, 2019.

[2] Wang, Jason, and Luis Perez. The effectiveness of data augmentation in image classification using deep learning, Convolutional Neural Networks Vis. Recognit, 2017.

[3] Mstafa, R. J., Younis, Y. M., Hussein, H. I., & Atto, M., A new video steganography scheme based on Shi-Tomasi corner detector. IEEE Access, vol. 8, pp. 161825-161837, 2020.

[4] Kenney, Charles S., Marco Zuliani, and B. S. Manjunath. An axiomatic approach to corner detection. IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05). vol. 1, 2005.